Министерство науки и высшего образования Российской Федерации



Федеральное государственное вюджетное образовательное учреждение высшего образования Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет) (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	«Информатика и системы управления»		
КАФЕДРА	«Программное обеспечение ЭВМ и информационные технологии»		
НАПРАВЛЕНІ	ИЕ ПОДГОТОВКИ «09.03.04 Программная инженерия»		

ОТЧЕТ по лабораторной работе №1

Название:	Расстояние Левенштейна и Дамерау – Левенштейна			
Дисциплина:		Анализ алгоритмов		
Студент	ИУ7-56Б Группа	Подпись, дата	Ковель А.Д. И. О. Фамилия	
Преподаватель		Подпись, дата	Волкова Л.Л. И.О.Фамилия	

Оглавление

Ана	литический раздел
1.1	Расстояние Левенштейна
1.2	Расстояние Дамерау – Левенштейна
1.3	Рекурсивная формула
1.4	Матрица расстояний
1.5	Рекурсивный алгоритм расстояния Дамерау – Левенштейна с
	мемоизацией
1.6	Вывод
Кон	иструкторский раздел
2.1	Матричные итерационные алгоритмы
2.2	Модификация матричных алгоритмов
2.3	Рекурсивные алгоритмы
2.4	Вывод
Tex	нологический раздел
3.1	Требования к ПО
3.2	Средства реализации
3.3	Листинги кода
	3.3.1 Реализация алгоритмов
	3.3.2 Утилиты
3.4	Тестовые данные
3.5	Вывод
Исс	ледовательская часть
4.1	Технические характеристики
4.2	Время выполнения алгоритмов
1.4	
4.3	Использование памяти
	1.1 1.2 1.3 1.4 1.5 1.6 Кон 2.1 2.2 2.3 2.4 Tex 3.1 3.2 3.3

Введение

Нахождение редакционного расстояния одна из задач компьютерной лингвистики, которая находит применение в огромном количестве областей, начиная от предиктивных систем набора текста и заканчивая разработкой искусственного интеллекта. Впервые задачу поставил советский ученый В. И. Левенштейн [1], впоследствии её связали с его именем. В данной работе будут рассмотрены алгоритмы редакционного расстояния Левенштейна и расстояние Дамерау — Левенштейна [2].

Расстояния Левенштейна — метрика, измеряющая разность двух строк символов, определяемая в количестве редакторских операций (а именно удаления, вставки и замены), требуемых для преобразования одной последовательности в другую. Расстояние Дамерау — Левенштейна модификация, добавляющая к редакторским операциям транспозицию, или обмен двух соседних символов местами. Алгоритмы имеют некоторое количество модификаций, позволяющих эффективнее решать поставленную задачу. В данной работе будут предложены реализации алгоритмов, использующие парадигмы динамического программирования.

Цель лабораторной работы – получить навыки динамического программирования. Задачами лабораторной работы являются изучение и реализация алгоритмов Левенштейна и Дамерау – Левенштейна, применение парадигм динамического программирования при реализации алгоритмов и сравнительный анализ алгоритмов на основе экспериментальных данных.

В данной лабораторной работе будут рассмотрены разные реализации данных алгоритмов нахождения редакторских расстояний. Такие как: итеративный, рекурсивный и рекурсивный с кэшем.

Также будут приведены сравнения реализации по времени и памяти.

Аналитический раздел

Расстояние Левенштейна

Редакторское расстояние (расстояние Левенштейна) — это минимальное количество операций вставки, удаления и замены, необходимых для превращения одной строки в другую. Каждая редакторская операция имеет цену (штраф). В общем случае, имея на входе строку, $X = x_1 x_2 \dots x_n$, и, $Y = y_1 y_2 \dots y_n$, расстояние между ними можно вычислить с помощью операций:

- delete $(u, \varepsilon) = \delta$
- insert $(\varepsilon, v) = \delta$
- replace $(u,v)=\alpha(u,v)\leq 0$ (здесь, $\alpha(u,u)=0$ для всех u).

Необходимо найти последовательность замен с минимальным суммарным штрафом. Далее, цена вставки и удаления будет считаться равной 1. Пусть даны строки: s1 = s1[1..L1], s2 = s2[1..L2], s1[1..i] — подстрока s1длинной і, начиная с 1-го символа, s2[1..j] - подстрока s2 длинной ј, начиная с 1-го символа. Расстояние Левентштейна посчитывается следующей формулой:

$$D(s1[1..i], s2[1..j]) = \begin{cases} 0, & i = 0, j = 0, \\ i & j > 0, j = 0, \\ j, & j > 0, i = 0, \end{cases}$$

$$\min(D(s1[1..i-1], s2[1..j]) + 1$$

$$\min(D(s1[1..i-1], s2[1..j]) + 1$$

$$+ \begin{bmatrix} 0, & s1[i] = s2[j] \\ 1 \end{cases}$$

$$(1.1)$$

1.2 Расстояние Дамерау – Левенштейна

Расстояние Дамерау – Левенштейна — модификация расстояния Левенштейна, добавляющая транспозицию к редакторским операциям, предложенными Левенштейном (см. 1.1). изначально алгоритм разрабатывался для сравнения текстов, набранных человеком (Дамерау показал, что 80% человеческих ошибок при наборе текстов составляют перестановки соседних символов, пропуск символа, добавление нового символа, и ошибка в символе. Поэтому метрика Дамерау – Левенштейна часто используется в редакторских программах для проверки правописания).

Используя условные обозначения, описанные в разделе 1.1, рекурсивная формула для нахождения расстояния Дамерау—Левенштейна, f(i,j), между подстроками, $x_1 \dots x_i$ и, $y_1 \dots y_j$, имеет следующий вид:

$$f_{X,Y}(i,j) = \begin{cases} \delta_i & j = 0 \\ \delta_j & i = 0 \end{cases}$$

$$\min \begin{cases} \alpha(x_i, y_i) + f_{X,Y}(i-1, j-1) \\ \delta + f_{X,Y}(i-1, j) \\ \delta + f_{X,Y}(i, j-1) \\ \left[\delta + f_{X,Y}(i-2, j-2) \quad i, j > 1x_i = y_{j-1}x_{i-1} = y_j \right] \\ \infty & \text{иначе;} \end{cases}$$
(1.2)

1.3 Рекурсивная формула

Используя условные обозначения, описанные в разделе 1.2, рекурсивная формула для нахождения расстояния Дамерау – Левенштейна f(i,j) между

подстроками, $x_1 \dots x_i$, и, $y_1 \dots y_j$, имеет следующий вид:

$$f_{X,Y}(i,j) = \begin{cases} \delta_i & j = \\ \delta_j & i = \\ \alpha(x_i, y_i) + f_{X,Y}(i-1, j-1) \\ \delta + f_{X,Y}(i-1, j) \\ \delta + f_{X,Y}(i, j-1) \\ \left[\delta + f_{X,Y}(i-2, j-2) \quad i, j > 1x_i = y_{j-1}x_{i-1} = y_j \\ \infty & \text{иначе;} \end{cases}$$
(1.3)

 $f_{X,Y}$ — редакционное расстояние между двумя подстроками — первыми i символами строки X и первыми j символами строки Y. Можно вывести следующие утверждения:

- Если редакционное расстояние нулевое, то строки равны: $f_{X,Y}=0 \Rightarrow X=Y$
- Редакционное расстояние симметрично: $f_{X,Y} = f_{Y,X}$
- Максимальное значение $f_{X,Y}$ размерность более длинной строки: $f_{X,Y} \leq max(|X|,|Y|)$
- Минимальное значение $f_{X,Y}$ разность длин обрабатываемых строк: $f_{X,Y} \geq abs(|X|-|Y|)$
- Аналогично свойству треугольника, редакционное расстояние между двумя строками не может быть больше чем редакционные расстояния каждой из этих строк с третьей:

$$f_{X,Y} \le f_{X,Z} + f_{Z,Y}$$

1.4 Матрица расстояний

В алгоритме нахождения редакторского расстояния Дамерау – Левенштейна возможно использование матрицы расстояний.

Пусть, $C_{0...|X|,0...|Y|}$, — матрица расстояний, где, $C_{i,j}$ — минимальное количество редакторских операций, необходимое для преобразования подстроки, $x_1 \dots x_i$, в подстроку, $y_1 \dots y_j$. Матрица заполняется следующим образом:

$$Ci, j = \begin{cases} i & j = 0, \\ j & i = 0, \\ \min \begin{cases} C_{i-1,j-1} + \alpha(x_i, y_i), \\ C_{i-1,j} + 1, \\ C_{i,j-1} + 1 \end{cases}$$
 (1.4)

При решении данной задачи используется ключевая идея динамического программирования — чтобы решить поставленную задачу, требуется разбить на отдельные части задачи (подзадачи), после чего объединить решения подзадач в одно общее решение. Здесь небольшие подзадачи — это заполнение ячеек таблицы с индексами, i < |X|, j < |Y|. После заполнения всех ячеек матрицы в ячейке, $C_{|X|,|Y|}$, будет записано искомое расстояние.

1.5 Рекурсивный алгоритм расстояния Дамерау – Левенштейна с мемоизацией

При реализации рекурсивного алгоритма используется мемоизация — сохранение результатов выполнения функций для предотвращения повторных вычислений. Отличие от формулы 1.4 состоит лишь в начальной инициализации матрицы флагом ∞ , который сигнализирует о том, была ли обработана ячейка. В случае если ячейка была обработана, алгоритм переходит к следующему шагу.

1.6 Вывод

Были рассмотрены обе вариации алгоритма редакторского расстояния (Левенштейна и Дамерау – Левенштейна). Также были приведены разные способы реализации этих алгоритмов такие как: рекурсивный, итератив-

ный и рекурсивный с мемоизацией. Итеративный может быть реализован с помощью парадигм динамического программирования или матрицей расстояния. Рекурсивный с мемоизацией позволяет ускорить обычный рекурсивный алгоритм за счет матрицы, в которой промежуточные подсчеты.

2 Конструкторский раздел

В данном разделе представлены схемы реализуемых алгоритмов и их модификации.

2.1 Матричные итерационные алгоритмы

На рисунке 2.1 изображена схема алгоритма нахождения расстояния Дамерау – Левенштейна итеративно с использованием матрицы расстояний.

2.2 Модификация матричных алгоритмов

Мемоизация - это прием сохранения промежуточных результатов, которые могут еще раз понадобиться в ближайшее время, чтобы избежать их повторного вычисления. Матричный алгоритм нахождения расстояния Дамерау – Левенштейна может быть модифицирован, используя мемоизацию — достаточно инициализировать матрицу значением ∞, которое будет рассмотрено в качестве флага. На рисунке 2.2 изображена схема алгоритма, использующая этот прием.

2.3 Рекурсивные алгоритмы

На рисунке 2.3 изображена схема рекурсивного алгоритма нахождения расстояния Дамерау – Левенштейна.

2.4 Вывод

На основе формул и теоретических данных, полученных в аналитическом разделе, были спроектированы схемы алгоритмов.




Рисунок 2.1 – Схема итерационного алгоритма расстояния Дамерау – Левенштейна с заполнением матрицы расстояний




Рисунок 2.2 — Схема рекурсивного алгоритма расстояния Дамерау — Левенштейна с мемоизацией




Рисунок 2.3 — Схема рекурсивного алгоритма расстояния Дамерау — Левенштейна

3 Технологический раздел

3.1 Требования к ПО

Программа должна отвечать следующим требованиям:

- ПО корректно реагирует на любые действия пользователя;
- ПО возвращает полученное расстояние;
- ПО принимает текстовые данные в любой раскладке.
- Время отклика программы на любое действие пользователя должно быть приемлемым.

3.2 Средства реализации

Для реализации ПО был выбран компилируемый многопоточный язык программирования Golang, поскольку язык отличается легкой и быстрой сборкой программ, автоматическим управлением памяти и понятным синтаксисом. В качестве среды разработки была выбрана среда VS Code, запуск происходил через go run main.go.

3.3 Листинги кода

3.3.1 Реализация алгоритмов

В качестве представления строковых данных был выбран тип rune[3] – псевдоним для типа int32.

В листингах 3.1 - 3.3 приведены реализации алгоритмов, описанных в разделе 1.

Листинг 3.1 – Программный код нахождения расстояния Дамерау – Левенштейна итеративно

```
1 func CountDamNoRec(src, dest string) (int, MInt) {
    var (n, m, dist, shortDist, transDist int)
    srcRune, destRune := []rune(src), []rune(dest)
   n, m = len(srcRune), len(destRune)
    distMat := makeMatrix(n, m)
    for i := 1; i < n + 1; i++ {
10
      for j := 1; j < m + 1; j++ {
11
        insDist := distMat[i][j - 1] + 1
        delDist := distMat[i - 1][j] + 1
13
14
        match := 1
        if src[i - 1] == dest[j - 1] {
          match = 0
17
        eqDist := distMat[i - 1][j - 1] + match
19
        transDist = -1
        if i > 1 && j > 1 {
          transDist = distMat[i - 2][j - 2] + 1
23
        }
25
        if transDist != -1 \&\& srcRune[i - 1] == destRune[j - 2] \&\&
26
        srcRune[i - 2] == destRune[j - 1] {
          dist = getMinOfValues(insDist, delDist, eqDist, transDist)
28
29
          dist = getMinOfValues(insDist, delDist, eqDist)
        distMat[i][j] = dist
32
      }
33
    }
34
35
    shortDist = distMat[n][m]
37
    return shortDist, distMat
38
39 }
```

Листинг 3.2 – Программный код нахождения расстояния Дамерау – Левенштейна рекурсивно

```
func _countDamRecElem(src, dest []rune, i, j int) int {
  if (getMinOfValues(i, j) == 0) {
    return getMaxOf2Values(i, j)
  }
}
```

```
match := 1
    if (src[i - 1] == dest[j - 1]) {
      match = 0
    }
10
    insert := _countDamRecElem(src, dest, i, j - 1) + 1
    delete := _countDamRecElem(src, dest, i - 1, j) + 1
12
    replace := match+_countDamRecElem(src, dest, i - 1, j - 1)
13
14
    transpose := -1
15
16
    if i > 1 && j > 1 {
17
      transpose = _countDamRecElem(src, dest, i - 2, j - 2) + 1
18
    }
19
20
    min := 0
21
    if transpose != -1 && src[i - 1] == dest[j - 2]
22
    && src[i - 2] == dest[j - 1] {
      min = getMinOfValues(insert, delete, replace, transpose)
24
    } else {
25
      min = getMinOfValues(insert, delete, replace)
27
    return min
28
29 }
30
31 func CountDamRecNoCache(src, dest string) int {
32
    srcRune, destRune := []rune(src), []rune(dest)
33
   n, m := len(srcRune), len(destRune)
34
35
    return _countDamRecElem(srcRune, destRune, n, m)
36
37 }
```

Листинг 3.3 – Программный код нахождения расстояния

Дамерау – Левенштейна рекурсивно с кэшем

```
func _countDamRecElemCache(src, dest []rune, i, j int, distMat MInt) int {
   if (getMinOfValues(i, j) == 0) {
     return getMaxOf2Values(i, j)
   }
   if distMat[i][j] != -1 {
     return distMat[i][j]
   }
   match := 1
   if (src[i - 1] == dest[j - 1]) {
     match = 0
```

```
13
    }
14
    insert := _countDamRecElemCache(src, dest, i, j - 1, distMat) + 1
    delete := _countDamRecElemCache(src, dest, i - 1, j, distMat) + 1
16
    replace := match + _countDamRecElemCache(src, dest, i - 1, j - 1, distMat)
17
18
    transpose := -1
19
20
    if i > 1 && j > 1 {
      transpose = _countDamRecElemCache(src, dest, i - 2, j - 2, distMat) + 1
22
    }
23
^{24}
    min := 0
25
    if transpose != -1 && src[i - 1] == dest[j - 2]
26
    && src[i - 2] == dest[j - 1] {
      min = getMinOfValues(insert, delete, replace, transpose)
28
    } else {
29
      min = getMinOfValues(insert, delete, replace)
31
32
    distMat[i][j] = min
    return distMat[i][j]
34
35
36 }
37
38 func CountDamRecCache(src, dest string) int {
    srcRune, destRune := []rune(src), []rune(dest)
    n, m := len(srcRune), len(destRune)
40
41
42
    distMat := makeMatrixInf(n, m)
43
    return _countDamRecElemCache(srcRune, destRune, n, m, distMat)
44
45 }
```

3.3.2 Утилиты

В листингах 3.4 - 3.6 приведены используемые утилиты.

Листинг 3.4 – Функция нахождения минимума из N целых чисел

```
func getMinOfValues(values ...int) int {
   min := values[0]

for _, i := range values {
   if min > i {
      min = i
```

Листинг 3.5 – Функция нахождения максимума из двух целых чисел

```
func getMaxOf2Values(v1, v2 int) int {
   if v1 < v2 {
     return v2
   }
   return v1
}</pre>
```

Листинг 3.6 – Определение типа целочисленной матрицы; его

инициализация и вывод

```
type MInt [][]int
    func makeMatrix(n, m int) MInt {
      matrix := make(MInt, n + 1)
      for i := range matrix {
        matrix[i] = make([]int, m + 1)
      for i := 0; i < m + 1; i++ \{
        matrix[0][i] = i
11
12
13
      for i := 0; i < n + 1; i++ {
14
        matrix[i][0] = i
15
16
      return matrix
17
18
19
20
    func (mat MInt) PrintMatrix() {
21
      for i := 0; i < len(mat); i++ {
22
        for j := 0; j < len(mat[0]); j++ {
          fmt.Printf("%3d ", mat[i][j])
24
25
        fmt.Printf("\n")
27
28 }
```

3.4 Тестовые данные

$N_{\overline{0}}$	S_1	S_2	DLIter	DLRec	DLRecCache
1	« »	« »	0	0	0
$\parallel 2$	«book»	«bosk»	1	1	1
3	«book»	«back»	2	2	2
$\parallel 4$	«book»	«bacc»	3	3	3
5	«aboba»	«acacb»	4	4	4
6	«дверь»	«деврь»	1	1	1
6	«дверь»	«дверь»	1	1	1

3.5 Вывод

На основе схем из конструкторского раздела были разработаны программные реализации требуемых алгоритмов.

4 Исследовательская часть

4.1 Технические характеристики

Тестирование выполнялось на устройстве со следующими техническими характеристиками:

- Операционная система Pop! OS 22.04 LTS [4] Linux [5];
- Память 16 GiB
- Процессор AMD® Ryzen 7 2700 eight-core processor × 16 [6]

Во время тестирования устройство было подключено к блоку питания и не нагружено никакими приложениями, кроме встроенных приложений окружения, окружением и системой тестирования.

4.2 Время выполнения алгоритмов

Алгоритмы тестировались при помощи профилирования – сбора характеристик работы программы: времени выполнения и затрат по памяти. Для каждой функции были написаны "бенчмарки"[7], представленные встроенными в Golang средствами. Бенчмарки, реализованные стандартными средствами Golang автоматически делают некоторое количество замеров, предоставляя результат с некоторой погрешностью.

Листинг 4.1 – Пример бенчмарка

```
func BenchmarkCountDamNoRec10(b *testing.B) {
   src := "abaoboaobj"
   dest := "da;ldfjalj"
   for i := 0; i < b.N; i++ {
      CountDamNoRec(src, dest)
   }
}</pre>
```

Результаты тестирования приведены в таблице. Прочерк в таблице означает что тестирование для этого набора данных не выполнялось.

Таблица 4.1 – Время выполнения алгоритмов

Длина	Время выполнения()			
строк	DRecMem	DLIter	DLRec	
5	2344	1114	17228	
10	6747	3142	109170295	
40	92218	36281	-	
80	402839	142910	-	
160	1582974	646498	-	
240	3505394	1348110	-	




Рисунок 4.1 — Сравнение рекурсивного с мемоизацией, итеративного и рекурсивного расстояния Дамерау — Левенштейна




Рисунок 4.2 — Сравнение рекурсивного с мемоизацией, итеративного расстояния Дамерау — Левенштейна

4.3 Использование памяти

Максимальная глубина стека при вызове рекурсивных функций имеет следующий вид:

$$M_{recursive} = (n \cdot lvar + ret + ret_{int}) \cdot depth \tag{4.1}$$

Где:

n – количество аллоцированных локальных переменных;

lvar – размер переменной типа int

ret — адрес возврата;

 ret_{int} — возвращаемое значение;

depth — максимальная глубина стека вызова, которая равна $|S_1| + |S_2|$.

Использование памяти при итеративных реализациях:

$$M_{iter} = |S_1| + |S_2| + (|S_1| + 1 \cdot |S_2| + 1) \cdot lvar + n \cdot lvar + ret + ret_{int}$$
 (4.2)

Где $(|S_1| + 1 \cdot |S_2| + 1) \cdot lvar$ – место в памяти под матрицу расстояний.

4.4 Вывод

Рекурсивный алгоритм Дамерау – Левенштейна работает дольше итеративных реализаций – время этого алгоритма увеличивается в геометрической прогрессии с ростом размера строк. Рекурсивный алгоритм с мемоизацией превосходит простой рекурсивный алгоритм по времени. По расходу памяти все реализации проигрывают рекурсивной за счет большого количества выделенной памяти под матрицу расстояний. Стоит отметить, что для языков, где возможна передача указателя на массивы, самым эффективным и по времени, и по памяти будет алгоритм, использующий мемоизацию.

Заключение

В рамках лабораторной работы были рассмотрены три алгоритма нахождения расстояния Дамерау – Левенштейна. Во время аналитического изучения алгоритмов были выявлены смысловые различия между алгоритмами. Самая оптимальная реализация по памяти – рекурсивный алгоритм, самая оптимальная реализация по времени – итеративный алгоритм, использующий таблицу расстояний. Для языков, где возможна передача указателя на массивы, самым эффективным по времени и по памяти будет алгоритм, использующий мемоизацию. В ходе лабораторной работы получены навыки динамического программирования, реализованы изученные алгоритмы.

Литература

- [1] Левенштейн В. И. Двоичные коды с исправлением выпадений, вставок и замещений символов // Левенштейн, В. И. М.: Доклады АН СССР, 1965. Т. 163. С. 845–848.
- [2] Черненький В. М. Гапанюк Ю. Е. Методика идентификации пассажира по установочным данным // Черненький В. М., Гапанюк Ю. Е. М.: Вестник МГТУ им. Н.Э. Баумана. Сер. "Приборостроение", 2012. Т. 163. С. 30–34.
- [3] Go rune. Режим доступа: https://golangdocs.com/rune-in-golang (дата обращения: 04.09.2022).
- [4] Pop OS 22.04 LTS [Электронный ресурс]. Режим доступа: https://pop.system76.com (дата обращения: 04.09.2022).
- [5] Linux Википедия [Электронный ресурс]. Режим доступа: https://ru.wikipedia.org/wiki/Linux (дата обращения: 04.09.2022).
- [6] Процессор AMD® Ryzen 7 2700 eight-core processor × 16 [Электронный ресурс]. Режим доступа: https://www.amd.com/en/products/cpu/amd-ryzen-7-2700 (дата обращения: 04.09.2022).
- [7] Go 1 Release Notes. Режим доступа: https://pkg.go.dev/testing (дата обращения: 04.09.2022).